

Lab09

Set up

```
setwd('D:/STAT/Lab/Lab9')
data <- read.csv("insurance.csv", header=TRUE)
attach(data)
str(data)
```

```
## 'data.frame': 1338 obs. of 7 variables:
## $ age      : int  19 18 28 33 32 31 46 37 37 60 ...
## $ sex      : chr  "female" "male" "male" "male" ...
## $ bmi      : num  27.9 33.8 33 22.7 28.9 ...
## $ children: int   0 1 3 0 0 0 1 3 2 0 ...
## $ smoker   : chr   "yes" "no" "no" "no" ...
## $ region   : chr   "southwest" "southeast" "southeast" "northwest" ...
## $ charges  : num  16885 1726 4449 21984 3867 ...
```


```
head(data)
```

```
##   age    sex    bmi children smoker   region   charges
## 1  19 female 27.900         0    yes southwest 16884.924
## 2  18  male 33.770         1    no  southeast  1725.552
## 3  28  male 33.000         3    no  southeast  4449.462
## 4  33  male 22.705         0    no northwest 21984.471
## 5  32  male 28.880         0    no northwest  3866.855
## 6  31 female 25.740         0    no  southeast  3756.622
```

Visualize data

Age


```
barplot(table(age))
```



Độ tuổi tham gia bảo hiểm trải đều từ 18-63 tuổi.
 Trong đó, số lượng người tham gia bảo hiểm nhiều nhất tập trung ở độ tuổi 18.

Sex


```
pie(table(sex))
```



Nhận thấy không có sự chênh lệch về giới tính khách hàng tham gia mua bảo hiểm.


BMI

```
hist(bmi,breaks=30)
```




Chỉ số BMI có dạng phân phối chuẩn (Normal), với $\text{mean} = 30$, $\text{sd} = 12$

```
plot(age,bmi)
```




BMI vs AGE

```
boxplot(bmi~age)
```



Chỉ số bmi và age không ảnh hưởng đến nhau.
Bmi có thể phụ thuộc vào thói quen sinh hoạt.

```
boxplot(bmi~sex)
```




BMI vs SEX

Chỉ số bmi và sex không ảnh hưởng đến nhau.

Child


```
barplot(table(children))
```



Chủ yếu những gia đình có ít trẻ em sẽ tham gia mua bảo hiểm nhiều hơn.
Đặc biệt là nhóm không có trẻ em.

Smoker


```
barplot(table(smoker))
```

Chủ yếu người tham gia bảo hiểm là những người không hút thuốc.

Region

```
barplot(table(region))
```




Khu vực sinh sống của những người đăng kí mua bảo hiểm không có sự chênh lệch.

Charge

```
hist(charges,breaks=30)
```

Histogram of charges




Chi phí bảo hiểm bị lệch về bên phải (lệch về bên nào bên đó ít).
Xử lí: lấy log10 trên chi phí.

$\ln(\text{charge})$


```
lncharges <- log10(charges)
hist(lncharges,breaks=30)
```

Histogram of Incharges




Vẽ boxplot kiểm tra xem có outlier không.

```
boxplot(lncharges)
```




```
boxplot(charges)
```




ln(charges) vs age

```
boxplot(lncharges~age)
```




```
plot(age,lncharges)
```



Tuổi càng cao, chi phí bảo hiểm càng tăng -> Tương quan thuận

ln(charges) vs sex


```
boxplot(lncharges~sex)
```

Chi phí đồng bảo hiểm không ảnh hưởng bởi giới tính.

$\ln(\text{charges})$ vs bmi

```
plot(bmi, lncharges)
```




```
cor(bmi,lncharges)
```

```
## [1] 0.1326694
```

Chỉ số bmi có tương quan thuận đến chi phí nhưng không nhiều.

ln(charges) vs child


```
boxplot(lncharges~children)
```



Số trẻ em phụ thuộc vào bên bù bảo hiểm càng nhiều thì chi phí đóng bảo hiểm càng cao. Riêng với 5 trẻ em thì chi phí lại giảm, có thể do dữ liệu cho 5 trẻ em ít, hoặc có chính sách gì đó.

ln(charges) vs region

```
boxplot(lncharges~region)
```



Chi phí đóng là như nhau ở các khu vực sinh sống khác nhau.

bmi vs age

```
cor(age,bmi)
```

```
## [1] 0.1092719
```

Có thể sử dụng bmi với age để đưa vào mô hình.

Lập mô hình dự báo chi phí theo các biến bmi,age,smoker,sex,region

Kiểm định $\ln(\text{charges})$ có theo normal không.

Lập mô hình $\ln(\text{charges})$ theo bmi

```
model1 <- lm(lncharges~bmi)
summary(model1)
```

```
##
## Call:
## lm(formula = lncharges ~ bmi)
##
## Residuals:
```

```
##      Min      1Q   Median      3Q      Max
## -1.08093 -0.27593  0.01362  0.29535  0.84766
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 3.685094    0.055517  66.378 < 2e-16 ***
## bmi          0.008688    0.001776   4.892 1.12e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.396 on 1336 degrees of freedom
## Multiple R-squared:  0.0176, Adjusted R-squared:  0.01687
## F-statistic: 23.94 on 1 and 1336 DF,  p-value: 1.117e-06
```

Vì R^2 của mô hình rất thấp nên ta sẽ bổ sung các biến mới vào mô hình.

Lập mô hình $\ln(\text{charges})$ theo bmi, age

```
model2 <- lm(lncharges~bmi+age)
summary(model2)
```

```
##
## Call:
## lm(formula = lncharges ~ bmi + age)
##
## Residuals:
##      Min      1Q   Median      3Q      Max
## -0.6843 -0.1938 -0.1252  0.2296  0.9048
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 3.2201207  0.0517849  62.183 < 2e-16 ***
## bmi          0.0049703  0.0015254   3.258 0.00115 **
## age          0.0147670  0.0006621  22.304 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3381 on 1335 degrees of freedom
## Multiple R-squared:  0.2843, Adjusted R-squared:  0.2832
## F-statistic: 265.2 on 2 and 1335 DF,  p-value: < 2.2e-16
```

Mô hình cải thiện.

Bổ sung thêm các biến $\text{smoker}, \text{sex}$.

Lập mô hình $\ln(\text{charges})$ theo $\text{bmi}, \text{age}, \text{smoker}, \text{sex}$

```
model3 <- lm(lncharges~bmi+age+smoker+sex)
summary(model3)
```

```
##
## Call:
## lm(formula = lncharges ~ bmi + age + smoker + sex)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.51720 -0.09151 -0.01693  0.04300  0.91499
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.0843373   0.0313263   98.458 < 2e-16 ***
## bmi          0.0048015   0.0009104    5.274 1.55e-07 ***
## age          0.0152369   0.0003949   38.583 < 2e-16 ***
## smokeryes    0.6742349   0.0136972   49.224 < 2e-16 ***
## sexmale     -0.0307507   0.0110674   -2.778 0.00554 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2015 on 1333 degrees of freedom
## Multiple R-squared:  0.7461, Adjusted R-squared:  0.7453
## F-statistic: 979.1 on 4 and 1333 DF,  p-value: < 2.2e-16
```

R^2 của mô hình cải thiện hơn nhiều, p-value của các hệ số đều có ý nghĩa.
Cần nhắc tới việc thêm các biến tương tác.

Thêm biến bmi*sex

```
gender <- replicate(length(sex),0)
for(i in 1:length(gender)){
  if(sex[i]=="male")
    gender[i]=1
  else
    gender[i]=0
}
bmi_sex <- bmi*gender
model4 <- lm(lncharges~bmi+age+gender+smoker+bmi_sex)
summary(model4)

##
## Call:
## lm(formula = lncharges ~ bmi + age + gender + smoker + bmi_sex)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.53040 -0.09145 -0.01726  0.04402  0.91225
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.103264   0.042395   73.199 < 2e-16 ***
## bmi          0.004186   0.001301    3.218 0.00132 **
## age          0.015233   0.000395   38.562 < 2e-16 ***
## gender       -0.067564   0.056639   -1.193 0.23312
```

```
## smokeryes      0.673739    0.013721  49.105 < 2e-16 ***
## bmi_sex        0.001202    0.001814   0.663  0.50761
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2016 on 1332 degrees of freedom
## Multiple R-squared:  0.7461, Adjusted R-squared:  0.7452
## F-statistic: 783 on 5 and 1332 DF,  p-value: < 2.2e-16
```

Thêm biến bmi*smoke

```
smoke <- replicate(length(smoker),0)
for(i in 1:length(smoke)){
  if(smoker[i]=="yes")
    smoke[i]=1
  else
    smoke[i]=0
}

bmi_smoke <- bmi*smoke
model5 <- lm(lncharges~bmi+age+gender+smoke+bmi_smoke)
summary(model5)
```

```
##
## Call:
## lm(formula = lncharges ~ bmi + age + gender + smoke + bmi_smoke)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.41746 -0.08632 -0.01773  0.04001  0.93905
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.2129199   0.0335403   95.793 < 2e-16 ***
## bmi          0.0005647   0.0009992    0.565 0.572044
## age          0.0153299   0.0003835   39.974 < 2e-16 ***
## gender       -0.0356514   0.0107571   -3.314 0.000944 ***
## smoke         0.0822183   0.0664902    1.237 0.216473
## bmi_smoke     0.0193041   0.0021243    9.087 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1956 on 1332 degrees of freedom
## Multiple R-squared:  0.7609, Adjusted R-squared:  0.76
## F-statistic: 847.7 on 5 and 1332 DF,  p-value: < 2.2e-16
```

```
step(model5)
```

0.00001

```

## Start:  AIC=-4359.8
## lncharges ~ bmi + age + gender + smoke + bmi_smoke
##
##           Df Sum of Sq    RSS    AIC
## - bmi      1     0.012  50.997 -4361.5
## - smoke    1     0.059  51.043 -4360.3
## <none>                        50.984 -4359.8
## - gender   1     0.420  51.405 -4350.8
## - bmi_smoke 1     3.161  54.145 -4281.3
## - age      1    61.164 112.148 -3307.0
##
## Step:  AIC=-4361.48
## lncharges ~ age + gender + smoke + bmi_smoke
##
##           Df Sum of Sq    RSS    AIC
## - smoke      1     0.046  51.043 -4362.3
## <none>                        50.997 -4361.5
## - gender     1     0.418  51.414 -4352.6
## - bmi_smoke  1     4.279  55.275 -4255.7
## - age        1    62.107 113.104 -3297.7
##
## Step:  AIC=-4362.26
## lncharges ~ age + gender + bmi_smoke
##
##           Df Sum of Sq    RSS    AIC
## <none>                        51.043 -4362.3
## - gender     1     0.432  51.475 -4353.0
## - age        1    62.063 113.105 -3299.7
## - bmi_smoke  1   102.714 153.756 -2888.8

##
## Call:
## lm(formula = lncharges ~ age + gender + bmi_smoke)
##
## Coefficients:
## (Intercept)          age          gender      bmi_smoke
##      3.23072      0.01534     -0.03610       0.02188

```

Sau khi tìm được model tốt nhất, ta đi test với bộ dữ liệu test.